LAPORAN KEMAJUAN PROYEK UTS
DARI NEURON KE APLIKASI: MEMBANGUN SOLUSI DEEP LEARNING UNTUK MASALAH LOKAL

Topik 8: Prediksi Harga Komoditas Pangan

DOSEN PEMBIMBING :
NOVERA KRISTIANTI, S.T., M.T.

Disusun Oleh (Kelompok 5):

BRYAN DESMONDA FERDINAN	**(2330105030004)**
OLGA NOVIOLA AGUSTIN	**(2330105030028)**
TETY CITRA NATHA	**(2330105030022)**
RIZQULLAH FALAH MAHENDRA	**(2330105030016)**
LIA NELDA	**(223010503012)**

JURUSAN TEKNIK INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS PALANGKA RAYA

2026

BAB I
PENDAHULUAN

1.1 Latar Belakang

Bahan pangan pokok memegang peranan krusial dalam aspek ekonomi, sosial, dan politik suatu wilayah. Dinamika harga komoditas strategis, khususnya Beras Kualitas Medium I dan Cabai Merah Besar, seringkali bersifat sangat fluktuatif karena rentan terhadap faktor iklim, gangguan rantai pasok, maupun ketidakseimbangan antara permintaan dan penawaran. Secara tradisional, pemantauan dan analisis pergerakan harga pangan di tingkat nasional (yang mencakup data dari 38 provinsi di Indonesia) masih mengandalkan metode manual atau statistik konvensional, sehingga kurang responsif dalam mengantisipasi lonjakan harga yang mendadak.

Pemanfaatan *big data* dan *deep learning* telah merevolusi sektor finansial dan ekonomi, memungkinkan sistem untuk mengenali pola kompleks serta dependensi temporal dari puluhan ribu data historis yang tersedia pada basis data Pusat Informasi Harga Pangan Strategis (PIHPS) Nasional melalui laman resmi Bank Indonesia. Jaringan Saraf Tiruan (JST) tipe *Multilayer Perceptron* (MLP) yang dilatih menggunakan algoritma *backpropagation* mampu memodelkan hubungan non-linear dari fluktuasi harga tersebut dengan cara memperbarui bobot koreksi jaringan secara berulang. Proyek ini berfokus pada implementasi arsitektur *baseline* MLP regresi sebagai fondasi awal UTS, sebelum nantinya dikembangkan menjadi model sekuensial tingkat lanjut (seperti LSTM atau GRU) pada tahap UAS.

1.2 Rumusan Masalah

Bagaimana merancang, melatih, dan mengevaluasi arsitektur *baseline deep learning* berbasis *Multilayer Perceptron* (MLP) regresi untuk memprediksi harga harian nasional komoditas Beras Kualitas Medium I dan Cabai Merah Besar berdasarkan data historis deret waktu (*time-series*) yang bersumber dari PIHPS?

1.3 Tujuan

Membangun arsitektur *baseline* MLP regresi untuk peramalan harga kedua komoditas pangan, melakukan prapemrosesan data panel multi-provinsi menjadi format sekuensial univariat menggunakan teknik *sliding window*, serta mengevaluasi performa awal model menggunakan metrik kesalahan (*MSE, RMSE, dan MAE*) beserta analisis visual kurva eksperimen.

BAB II
TINJAUAN PUSTAKA SINGKAT

Pengembangan model *baseline* prediksi harga pangan ini didukung oleh kajian dari beberapa penelitian terdahulu yang relevan:

1. **Sari, P. D., & Ahyaningsih, F. (2024)**. *Jaringan Saraf Tiruan Backpropagation untuk Prediksi Harga Bahan Pangan di Wilayah Kabupaten Deli Serdang*. Penelitian ini membuktikan bahwa algoritma JST berbasis *backpropagation* efektif digunakan untuk memprediksi fluktuasi harga bahan pangan dengan tingkat akurasi mencapai 87,5% pada arsitektur optimalnya.
2. **Hamdi, I., dkk. (2023)**. *Prediksi Jumlah Perceraian Menggunakan Metode Multilayer Perceptron*. Studi ini memvalidasi penerapan arsitektur MLP pada data deret waktu (*time-series*), serta menunjukkan bahwa pengaturan parameter pelatihan dan rasio pembagian data (seperti 80:20 atau 90:10) sangat memengaruhi kestabilan nilai *Mean Squared Error* (MSE) yang dihasilkan.
3. **Sawitri, D. (2025)**. *Peran Deep Learning dan Big Data dalam Mendeteksi Masalah Keuangan*. Penelitian ini menegaskan bahwa pemanfaatan *deep learning* (termasuk arsitektur jaringan saraf) jauh lebih unggul dibandingkan metode statistik konvensional dalam menangani volume data ekonomi berskala besar untuk mendeteksi anomali tren pasar secara dinamis.

BAB III
DATASET & PREPROCESSING

Dataset yang digunakan bersumber langsung dari Pusat Informasi Harga Pangan Strategis (PIHPS) Nasional (diunduh melalui situs resmi *https://www.bi.go.id/hargapangan*). Proyek ini memanfaatkan dua *file* lembar kerja digital, yaitu *Tabel Harga Berdasarkan Komoditas - Beras Kualitas Medium I.xlsx* dan *Tabel Harga Berdasarkan Komoditas - Cabai Merah Besar.xlsx*. Data tersebut memuat catatan harga harian dari 38 provinsi di Indonesia sejak 1 Januari 2026 hingga 29 Oktober 2026, yang jika diakumulasikan menghasilkan lebih dari 16.000 baris data (telah melampaui syarat minimum 5.000 sampel).

Tahapan *preprocessing* data diimplementasikan menggunakan pustaka Pandas dan NumPy di Python melalui tahapan berikut:

1) **Deteksi Header & Pembersihan Format:** Sistem mendeteksi baris tabel secara otomatis, membuang kolom nomor serta baris rekapitulasi nasional bawaan Excel, serta mengubah string teks harga (termasuk tanda titik ribuan dan karakter kosong/strip - akibat hari libur pasar) menjadi format angka desimal numerik.
2) **Agregasi Nasional & Forward-Fill:** Nilai harga harian dari seluruh provinsi diagregasikan menjadi rata-rata nasional harian. Data hari libur yang kosong ditambal menggunakan metode *forward-fill* dan *backward-fill* agar urutan tanggal tetap kontinu tanpa terputus.
3) **Normalisasi (MinMaxScaler):** Seluruh rentang harga dinormalisasi ke dalam skala interval $[0,1]$ agar proses optimasi gradien oleh model berjalan stabil dan konvergen lebih cepat.
4) **Transformasi Sliding Window:** Mengubah deret waktu menjadi matriks sampel pengawasan (*supervised learning*) dengan menetapkan window_size = 14 (artinya, harga historis 14 hari ke belakang digunakan sebagai fitur untuk memprediksi harga pada hari ke-15).

5) **Pemisahan Data (Splitting):** Himpunan data dibagi secara kronologis secara berurutan tanpa pengacakan (shuffle=False) dengan rasio 80% data latih (*train*), 10% data validasi (*val*), dan 10% data uji (*test*).

BAB IV
METODOLOGI

Tahap UTS difokuskan pada perancangan model *baseline* menggunakan *Multilayer Perceptron* (MLP) regresi. Berbeda dengan model spasial, MLP menerima masukan vektor sekuensial yang diratakan (*flattened*), kemudian meneruskan sinyal secara *feedforward* melalui lapisan tersembunyi (*hidden layers*) sebelum diperbarui bobotnya via *backpropagation*. Seluruh proses eksperimen dan pelatihan model dieksekusi secara lokal menggunakan akselerasi perangkat keras GPU NVIDIA GeForce RTX 3050 Laptop.

Arsitektur Model MLP:

1) **Input Layer:** Menerima 14 fitur masukan dari jendela waktu historis (*sliding window*).
2) **Hidden Layers:** Terdiri dari dua *Dense Layer* (64 neuron pada lapisan pertama dan 32 neuron pada lapisan kedua), masing-masing dilengkapi dengan fungsi aktivasi non-linear *Rectified Linear Unit* (ReLU).
3) **Output Layer:** Satu neuron dengan aktivasi linear untuk mengeluarkan estimasi nilai regresi harga tunggal di hari berikutnya ($t + 1$).
4) **Parameter Kompilasi:** Model dioptimalkan menggunakan *optimizer* Adam dengan tingkat pembelajaran (*learning rate*) sebesar 0.001, fungsi kerugian *Mean Squared Error* (MSE), ukuran *batch size* 32, dan total pelatihan sebanyak 50 *epochs*.

BAB V
EKSPERIMEN & HASIL

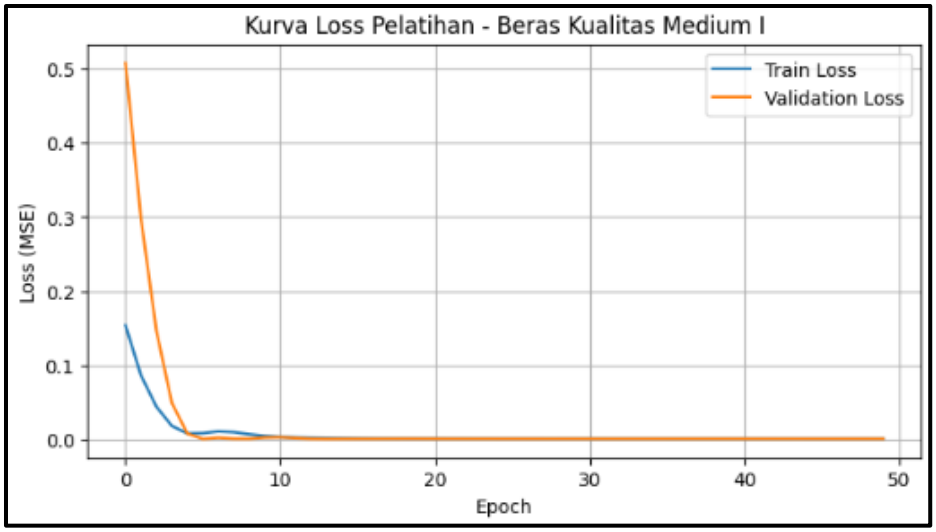
Pelatihan model berhasil dieksekusi secara terpisah untuk kedua komoditas. Berdasarkan evaluasi pada himpunan data uji (*test set*), diperoleh rekapitulasi metrik kesalahan (*Error Metrics*) sebagai berikut:

Tabel 1. Tabel Evaluasi Himpunan Data Uji

Komoditas Pangan	**Arsitektur Model**	**MSE**	**RMSE**	**MAE**
Beras Kualitas Medium I	MLP Regresi (*Baseline*)	477.20	21.84	19.28
Cabai Merah Besar	MLP Regresi (*Baseline*)	2566281.99	1601.96	1264.80

5.1 Analisis Visual Hasil Eksperimen:

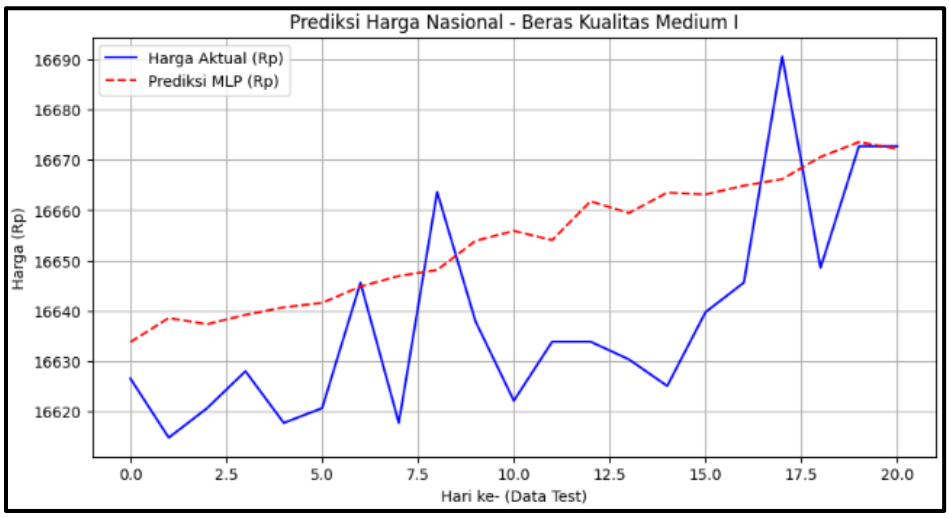
1. **Kurva Loss Pelatihan — Beras Kualitas Medium I:**



Gambar 1. Kurva Loss Pelatihan – Beras Kualitas Medium I

Grafik ini menampilkan pergerakan *Train Loss* (garis biru) dan *Validation Loss* (garis oranye) selama 50 *epochs*. Terlihat bahwa kedua kurva menurun secara drastis pada awal iterasi dan konvergen secara mulus tanpa adanya tanda-tanda *overfitting*, yang membuktikan bahwa proses belajar bobot jaringan berjalan sangat stabil.

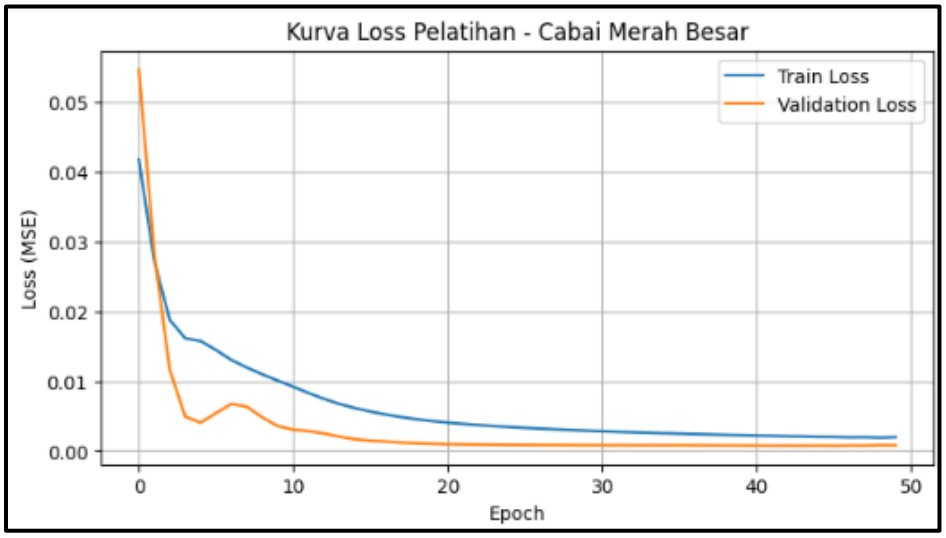
2. Grafik Prediksi vs Harga Aktual — Beras Kualitas Medium I:



Gambar 2. Grafik Prediksi vs Harga Aktual – Beras Kualitas Medium I

Grafik perbandingan antara garis harga aktual di pasar (warna biru) dan garis tebakan model MLP (garis merah putus-putus). Model *baseline* MLP mampu mengikuti arah tren harga beras nasional secara umum, meskipun terdapat sedikit selisih rata-rata (*margin error*) karena karakteristik komoditas beras yang cenderung stabil dan bergerak lambat.

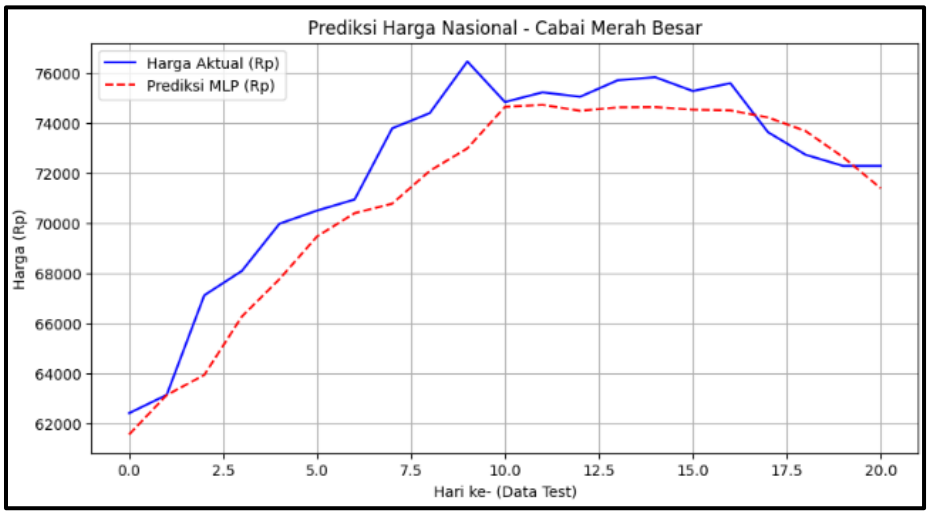
3. Kurva Loss Pelatihan — Cabai Merah Besar:



Gambar 3. Kurva Loss Pelatihan – Cabai Merah Besar

Menunjukkan tren penurunan *loss* yang konsisten pada komoditas cabai merah. Penurunan kurva yang stabil mengonfirmasi bahwa parameter *learning rate* (0.001) dan fungsi aktivasi ReLU sudah sesuai dalam meminimalkan kesalahan kuadrat (*MSE*) pada data komoditas hortikultura.

4. Grafik Prediksi vs Harga Aktual — Cabai Merah Besar



Gambar 4. Grafik Prediksi vs Harga Aktual – Cabai Merah Besar

Menampilkan hasil peramalan harga cabai merah pada data *test*. Terlihat bahwa model MLP mampu merespons arah pergerakan tren harga, namun mengalami sedikit keterlambatan respons (*lagging effect*) saat terjadi lonjakan harga yang ekstrem. Hal ini wajar terjadi pada model *baseline* MLP karena ketiadaan struktur memori internal.

5.2 Pembahasan

Berdasarkan hasil eksperimen di atas, arsitektur *baseline* MLP regresi terbukti berhasil mengekstrak pola historis dan memetakan hubungan sekuensial dari data harian PIHPS untuk kedua komoditas. Namun, analisis mendalam terhadap grafik prediksi menunjukkan adanya kelemahan mendasar: model MLP kurang optimal ketika menghadapi volatilitas harga yang tajam (seperti pada komoditas cabai merah). Keterbatasan ini disebabkan oleh sifat arsitektur *feedforward* MLP yang tidak memiliki mekanisme penyimpanan konteks jangka panjang (*long-term dependencies*), sehingga model cenderung menghasilkan kurva prediksi yang lebih landai dan terlambat merespons perubahan tren mendadak di pasar.

BAB VI
KESIMPULAN & RENCANA LANJUTAN

Fondasi *deep learning* untuk peramalan harga komoditas pangan nasional (Beras Medium I dan Cabai Merah Besar) telah berhasil dibangun menggunakan model MLP regresi. Rangkaian prapemrosesan data PIHPS—mulai dari pembersihan format, agregasi nasional, normalisasi min-max, hingga pembentukan jendela waktu sekuensial—telah teruji dan valid menghasilkan model yang konvergen.

Untuk mengatasi keterbatasan *baseline* MLP dalam menangkap volatilitas harga ekstrem, pengembangan tahap UAS akan ditingkatkan menggunakan arsitektur *Recurrent Neural Network* (RNN) tingkat lanjut, khususnya **LSTM (*Long Short-Term Memory*)** atau **GRU**. Arsitektur berbasis gerbang memori ini dinilai jauh lebih unggul dalam mempertahankan informasi historis jangka panjang. Selain itu, pada tahap UAS juga akan diterapkan optimalisasi *hyperparameter* (menggunakan *Optuna* atau *Grid Search*), studi ablasi, interpretabilitas model, serta *deployment* purwarupa aplikasi antarmuka interaktif berbasis web menggunakan *Streamlit*.

LAMPIRAN

Tabel Pembagian Tugas Kelompok:

Nama Anggota / Peran	**Rincian Tugas & Kontribusi Nyata**
Bryan Desmonda Ferdinan *(Model Engineer I)*	Merancang arsitektur kode *baseline* MLP regresi, mengatur parameter pelatihan PyTorch, dan mengeksekusi *training* model di Google Colab.
Rizqullah Falah Mahendra *(Model Engineer II)*	Membantu tugas Model Engineer I agar lebih efisien
Tety Citra Natha *(Data Engineer)*	Mengunduh dan mengelola dataset Excel resmi dari PIHPS, menulis fungsi prapemrosesan data, serta menerapkan logika *sliding window*.
Lia Nelda *(Evaluator)*	Menganalisis log pelatihan, menghitung metrik evaluasi (*MSE, RMSE, MAE*), serta merender dan merapikan dokumentasi visual grafik.
Olga Noviola Agustin *(Penulis Laporan / Presenter)*	Menyusun struktur narasi Laporan Kemajuan UTS, menyiapkan bahan presentasi kelompok, serta mengunggah kode ke repositori GitHub.